hadoop-wordcount

211870287 丁旭

September 2023

1 hadoop 环境配置

1. 远程连接 ECS 实例

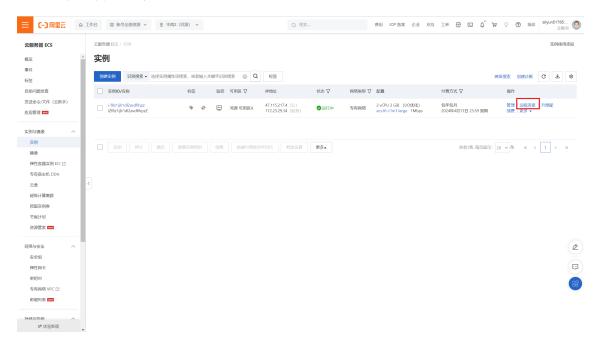


图 1: 云服务器控制台界面

- 2. 安装 jdk1.8
 - (a) 下载 JDK 安装包

wget https://download.java.net/openjdk/jdk8u41/ri/ (接)openjdk-8u41-b04-linux-x64-14_jan_2020.tar.gz

(b) 解压 JDK 安装包

 $tar - zxvf openjdk - 8u41 - b04 - linux - x64 - 14_jan_2020.tar.gz$

(c) 移动并重命名 JDK 安装包

mv java-se-8u41-ri//usr/java8

(d) 配置 java 环境

echo 'export JAVA_HOME=/usr/java8' >> /etc/profile echo 'export PATH=\$PATH:\$JAVA_HOME/bin' >> /etc/profile source /etc/profile

(e) 查看 java 是否安装

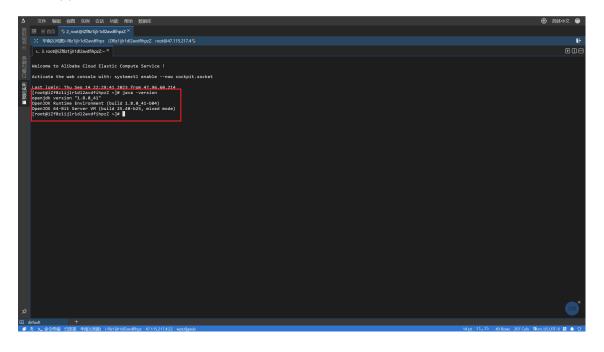


图 2: java 验证: java -version

3. 安装 Hadoop

(a) 下载 Hadoop 安装包

wget https://mirrors.bfsu.edu.cn/apache/hadoop/common/hadoop-2.10.1/l

(b) 解压 Hadoop 安装包至/opt/hadoop

```
\begin{array}{lll} tar & -zxvf & hadoop -2.10.1.\,tar.\,gz & -\!C\ /opt/\\ mv & /opt/hadoop -2.10.1\ /opt/hadoop \end{array}
```

(c) 配置 Hadoop 环境变量

```
echo 'export HADOOP_HOME=/opt/hadoop/' >> /etc/profile echo 'export PATH=$PATH:$HADOOP_HOME/bin' >> /etc/profile echo 'export PATH=$PATH:$HADOOP_HOME/sbin' >> /etc/profile source /etc/profile
```

(d) 修改配置文件 yarn-env.sh 和 hadoop-env.sh

```
echo "export JAVA_HOME=/usr/java8" >> /opt/hadoop/etc/hadoop/yarn-env.sh

echo "export JAVA_HOME=/usr/java8" >> /opt/hadoop/etc/hadoop/hadoop-env.sh
```

(e) 验证 Hadoop 是否安装成功

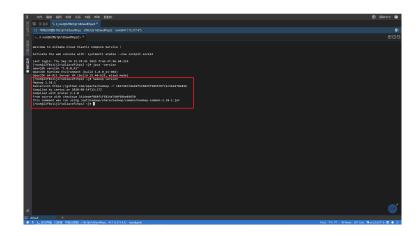


图 3: hadoop 安装验证

4. 配置 Hadoop

```
进入编辑界面
 vim /opt/hadoop/etc/hadoop/core-site.xml
 在<configuration></configuration>节点内, 插入如下内容。
 cproperty>
     <name>hadoop.tmp.dir</name>
     <value>file:/opt/hadoop/tmp</value>
     <description>location to store temporary files</description>
 cproperty>
     <name>fs.defaultFS</name>
     <value>hdfs://localhost:9000</value>
 进入编辑界面
 vim /opt/hadoop/etc/hadoop/hdfs-site.xml
 在<configuration></configuration>节点内, 插入如下内容
 cproperty>
     <name>dfs.replication </name>
     <value>1</value>
 cproperty>
     <name>dfs.namenode.name.dir</name>
     <value>file:/opt/hadoop/tmp/dfs/name</value>
 cproperty>
     <name>dfs.datanode.data.dir</name>
     <value>file:/opt/hadoop/tmp/dfs/data</value>
 5. 配置 SSH 免密登录
  创建公钥和私钥
```

ssh-keygen -t rsa

执行以下命令,将公钥添加到authorized_keys文件中cd .sshcat id_rsa.pub >> authorized_keys

2 启动 hadoop

- 1. 执行以下命令,初始化 namenode hadoop namenode —format
- 2. 依次执行以下命令,启动 Hadoop start-dfs.sh start-yarn.sh
- 3. 查看成功启动的进程

```
3 OF Note 1000 See Note 1000 Content place of the State of the State
```

图 4: hadoop 启动验证

4. 打开浏览器访问 http://<ECS 公网 IP>:8088 和 http://<ECS 公网 IP>:50070



图 5: http://<ECS 公网 IP>:8088

| Hadoop | Overview | Datanodes | Datanode Volume Failures | Snapshot | Startup Progress | Utilities |
|-------------|----------|-----------|--------------------------|----------|------------------|-----------|
| | | | | | | |
| Hadoop, 202 | 00 | | | | | |

图 6: http://<ECS 公网 IP>:50070

3 scala 环境配置

- 1. 进入到/usr/local/share 文件夹cd /usr/local/share
- 2. 安装包下载

wget https://downloads.lightbend.com/scala/2.12.6/scala-2.12.6.tgz

3. 解压文件

tar -xvzf scala -2.12.6.tgz

4. 添加环境变量

vim /etc/profile export PATH="\$PATH:/usr/local/share/scala-2.12.6/bin" source /etc/profile

5. scala 环境检验

```
[root@izf8z1ij]r1d12avdfihpzZ ~]# scala
Welcome to Scala 2.12.6 (OpenJDK 64-Bit Server VM, Java 1.8.0_41).
Type in expressions for evaluation. Or try :help.
scala> println("Hello, World!")
Hello, World!
scala>
scala>
```

图 7: scala: hello,world!

4 在 hadoop 环境下编写 scala 的 wordcount

1. 启动 hadoop

```
cd /usr/hadoop/hadoop-2.6.2/
sbin/start-dfs.sh
sbin/start-yarn.sh
```

2. 创建本地数据文件

```
cd ~/
mkdir ~/file
cd file
echo "Hello World , welcome to Big Data Analysis" > test1.txt
echo "Big Data Analysis is a good lesson " > test2.txt
```

3. 创建 scala 代码

```
import java.io.File
import scala.io.Source
object WordCount {
  def main(args: Array[String]): Unit = {
    val dirfile=new File(args(0))
    val files=dirfile.listFiles
    for(file <- files) println(file)
    val listFiles=files.toList
    val wordsMap=scala.collection.mutable.Map[String,Int]()
    listFiles.foreach( file =>Source.fromFile(file).getLines().foreach(line=>line.split(" ").
```

```
for each (
                           word = > \{
                             if (wordsMap.contains(word)) {
                               \operatorname{wordsMap}(\operatorname{word})+=1
                             }else {
                               \operatorname{wordsMap} = (\operatorname{word} - > 1)
                           }
                      )
                )
       println (wordsMap)
       for((key,value)<-wordsMap) println(key+": "+value)
    }
  }
4. 将数据文件传到 HDFS 的 input 目录下
  hadoop fs -mkdir /input
  hadoop fs -put ~/file/test*.txt /input
  sbin/start-yarn.sh
5. 运行程序
       第一种运行方式
  hadoop jar /opt/hadoop/share/hadoop/mapreduce/hadoop-mapreduce
  -examples -2.10.1.jar wordcount /input /output
       第二种运行方式
  编写 build . sh
  #!/bin/bash
  # 设置输出 Jar 文件的名称
  JAR_NAME="WordCount.jar"
```

编译 Scala 文件 scalac WordCount.scala

创建临时目录并将编译生成的 .class 文件复制到该目录中mkdir tmp find . —name '*.class' —exec cp {} tmp/ \;

创建空的 MANIFEST.MF 文件 touch MANIFEST.MF

在 MANIFEST.MF 文件中写入主类的信息,替换 "com.example.MainClass" 为你echo "Main-Class: WordCount" >> MANIFEST.MF

打包 .class 文件和 MANIFEST.MF 文件为 Jar 文件 jar cfm \$JAR_NAME MANIFEST.MF —C tmp .

删除临时目录和 MANIFEST.MF 文件rm -rf tmp MANIFEST.MF

运行 build.sh
sh build.sh
配置 hadoop的 scala 环境
export HADOOP_CLASSPATH=\$HADOOP_CLASSPATH:/usr/local/share
/scala -2.12.6/lib/*
source ~/.bashrc

在hadoop环境运行scala的jar包 hadoop jar /root/wordcount/WordCount.jar /root/file

```
## The content of th
```

图 8: 第一种方式在 hadoop 环境下,运行 scala 的 wordcount

```
### RANK ##
```

图 9: 第二种方式在 hadoop 环境下,运行 scala 的 wordcount

6. 查看结果

hadoop fs -cat /output/part-r-00000

```
pytes Wilten-S4

[root@iZf8z1ijlr1d12avdfihpzZ ~]# hadoop fs -cat /output/part-r-00000

, 1

Analysis 2

Big 2

Data 2

Hello 1

World 1

a 1

good 1

is 1

lesson 1

to 1

welcome 1

[root@iZf8z1ijlr1d12avdfihpzZ ~]#
```

图 10: 统计 test1 文件和 test2 文件内所有单词的词频

7. 结果验证

| Word | Count | | |
|----------|-------|--|--|
| Analysis | 2 | | |
| Big | 2 | | |
| Data | 2 | | |
| Hello | 1 | | |
| World | 1 | | |
| a | 1 | | |
| good | 1 | | |
| is | 1 | | |
| lesson | 1 | | |
| to | 1 | | |
| welcome | 1 | | |

输出正确,程序运行正常

5 清理——终止实例服务

在云服务器管理控制台停止用例

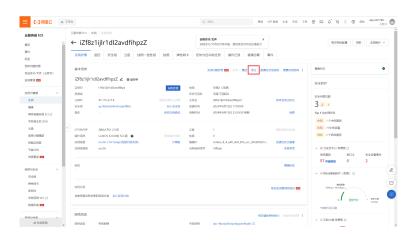


图 11: 终止实例

6 过程中的挑战及如何克服

- 1. 先需要找出哪个供应商有免费的学生服务,最后在阿里云中免费申请了7个月的云
- 2. 不知道什么是 bda 环境,通过查询资料,最终选择 hadoop 作为作业的 bda 环境
- 3. 配置环境是最复杂也是最繁琐的一项工程,因为我对这些东西一无所知,通过查询阿里云的官方文档已经搜索 csdn 和 chatgpt,才最终配置好了 hadoop、scala。
- 4. 不懂如何在 hadoop 中运行 scala 代码,通过查询资料,渐渐明白了 hadoop 和 scala 的关系,将 scala 代码打包成 jar, 然后在 Hadoop 中运行。